

# Brecha de género en ingreso laboral

Problem Set 1 · Sección 2

Julián Herrera   Andrés Silva   Valentina Vera

MECA 4107 · Big Data and Machine Learning para Economía Aplicada  
Universidad de los Andes

2026-20 · Grupo 3

## Result overview

21.2 %

menos ingreso  
(mujeres)

brecha incondicional

19.6 %

brecha preferida

edad, educación,  
horas y relab

Capital humano **amplía** la brecha (de 21.2 % a 27.2 %): las mujeres de la muestra son, en promedio, más educadas, así que no controlar educación subestima  $\beta$ . Horas y tipo de ocupación la comprimen hasta 19.6 %. Esa caída sí puede ser un bad control. Picos: hombres 50.5 (IC [49.1, 52.3]); mujeres 45.6 (IC [44.4, 47.0]).

Coeficiente preferido =  $-0.218$  (EE analítico 0.012; EE bootstrap FWL 0.012).  $N = 14,761$ .


# Pregunta y decisión metodológica

La elección de controles es el resultado de esta sección

¿Cuánto de la brecha sobrevive cuando condicionamos en características que una autoridad tributaria observa, y cuáles de esas características no deberíamos condicionar si el objeto es la brecha *causal*?

- **Buenos controles:** edad y educación. Están (en gran parte) determinadas antes del salario corriente.
- **Controles discutibles:** horas y relab. Pueden ser el canal de la brecha (selección a tiempo parcial, segregación ocupacional).
- **Malos controles claros:** formalidad y tamaño de firma, si el interés es discriminación. Útiles si el interés es predicción.

# La brecha no es un artefacto de un solo nivel educativo



# Especificaciones

$$\log(w_i) = \alpha + \beta \text{Mujer}_i + u_i$$

$$\log(w_i) = \alpha + \beta \text{Mujer}_i + f(\text{Edad}_i) + \gamma' \text{Educ}_i + u_i$$

$$\log(w_i) = \alpha + \beta \text{Mujer}_i + f(\text{Edad}_i) + \gamma' \text{Educ}_i + \theta \text{Horas}_i + \delta' \text{Relab}_i + u_i$$

- $\beta$  se reporta también como  $100(e^\beta - 1)$ : diferencia porcentual aproximada.
- Especificación preferida: capital humano *más* horas y relab. Es la más útil para fiscalización; no es la más limpia para causalidad.
- FWL: el mismo  $\beta$  se obtiene residualizando  $\log(w)$  y Mujer respecto a los controles.

## La brecha se comprime, no desaparece

| Specification                                | Female coefficient | Analytical SE | Bootstrap SE | Gap in percent | R <sup>2</sup> | N      |
|----------------------------------------------|--------------------|---------------|--------------|----------------|----------------|--------|
| Unconditional                                | -0.238             | 0.015         | —            | -21.2          | 0.018          | 14,761 |
| Human capital (age, education)               | -0.318             | 0.013         | —            | -27.2          | 0.264          | 14,761 |
| Preferred (add hours and employment type)    | -0.218             | 0.012         | 0.012        | -19.6          | 0.398          | 14,761 |
| Job attributes (add formality and firm size) | -0.209             | 0.011         | —            | -18.9          | 0.474          | 14,761 |


EE bootstrap solo en la especificación preferida, vía FWL. El resto usa EE analíticos OLS.

## FWL recupera el mismo coeficiente

| OLS female coefficient | FWL coefficient | Analytical SE | FWL bootstrap SE | Absolute difference |
|------------------------|-----------------|---------------|------------------|---------------------|
| -0.218083              | -0.218083       | 0.0120        | 0.0120           | 0.00000000          |

- FWL no cambia la interpretación:  $\beta$  sigue siendo la diferencia en log ingreso *dentro* de la variación de “mujer” que no es linealmente explicada por los controles.
- El EE bootstrap es un chequeo de infencia, no un estimador distinto.
- Si FWL y OLS no coincidieran, habría un error de implementación. Coinciden.

# Perfiles por género, especificación preferida





# Lectura

- Una autoridad que ignore el género va a **sobreprededir** el ingreso de las mujeres y marcarlas como subdeclarantes con más frecuencia. Eso no es neutral.
- Una autoridad que condicione en ocupación “explica” parte de la brecha con segregación. Para auditoría puede ser correcto; para equidad, no.
- Los picos distintos (50.5 vs. 45.6) implican que el ciclo de vida no es el mismo. Un perfil único por edad es una mala regla para ambos grupos.

## Takeaway

La brecha incondicional es 21.2 %. Condicionar en educación la sube a 27.2 % (efecto supresor). Con horas y tipo de ocupación queda en 19.6 %. El número del informe depende de si el objeto es causalidad o predicción. Nosotros reportamos la secuencia y usamos la especificación preferida para la DIAN.