

Brecha de género en ingreso laboral

Problem Set 1 · Sección 2

Julián Herrera Andrés Silva Valentina Vera

Ms Economía PEG · Big Data and Machine Learning para Economía Aplicada
Universidad de los Andes

2026-20 · Grupo 3

Result overview

21.2 %

menos ingreso
(mujeres)

brecha incondicional

19.6 %

brecha preferida

edad, educación,
horas y relab

Capital humano **amplía** la brecha (de 21.2 % a 27.2 %): las mujeres de la muestra son, en promedio, más educadas, así que no controlar educación subestima β . Horas y tipo de ocupación la comprimen hasta 19.6 %. Esa caída sí puede ser un bad control. Picos: hombres 50.5 (IC [49.1, 52.3]); mujeres 45.6 (IC [44.4, 47.0]).

Coeficiente preferido = -0.218 (EE analítico 0.012; EE bootstrap FWL 0.012). $N = 14,761$.


Pregunta y decisión metodológica

La elección de controles es el resultado de esta sección

¿Cuánto de la brecha sobrevive cuando condicionamos en características que una autoridad tributaria observa, y cuáles de esas características no deberíamos condicionar si el objeto es la brecha *causal*?

- **Buenos controles:** edad y educación. Están (en gran parte) determinadas antes del salario corriente.
- **Controles discutibles:** horas y relab. Pueden ser el canal de la brecha (selección a tiempo parcial, segregación ocupacional).
- **Malos controles claros:** formalidad y tamaño de firma, si el interés es discriminación. Útiles si el interés es predicción.

La brecha no es un artefacto de un solo nivel educativo



Especificaciones

$$\log(w_i) = \alpha + \beta \text{Mujer}_i + u_i$$

$$\log(w_i) = \alpha + \beta \text{Mujer}_i + f(\text{Edad}_i) + \gamma' \text{Educ}_i + u_i$$

$$\log(w_i) = \alpha + \beta \text{Mujer}_i + f(\text{Edad}_i) + \gamma' \text{Educ}_i + \theta \text{Horas}_i + \delta' \text{Relab}_i + u_i$$

- β se reporta también como $100(e^\beta - 1)$: diferencia porcentual aproximada.
- Especificación preferida: capital humano *más* horas y relab. Es la más útil para fiscalización; no es la más limpia para causalidad.
- FWL: el mismo β se obtiene residualizando $\log(w)$ y Mujer respecto a los controles.

La brecha se comprime, no desaparece

Specification	Female coefficient	Analytical SE	Bootstrap SE	Gap in percent	R ²	N
Unconditional	-0.238	0.015	—	-21.2	0.018	14,761
Human capital (age, education)	-0.318	0.013	—	-27.2	0.264	14,761
Preferred (add hours and employment type)	-0.218	0.012	0.012	-19.6	0.398	14,761
Job attributes (add formality and firm size)	-0.209	0.011	—	-18.9	0.474	14,761


EE bootstrap solo en la especificación preferida, vía FWL. El resto usa EE analíticos OLS.

FWL recupera el mismo coeficiente

OLS female coefficient	FWL coefficient	Analytical SE	FWL bootstrap SE	Absolute difference
-0.218083	-0.218083	0.0120	0.0120	0.00000000

- FWL no cambia la interpretación: β sigue siendo la diferencia en log ingreso *dentro* de la variación de “mujer” que no es linealmente explicada por los controles.
- El EE bootstrap es un chequeo de infencia, no un estimador distinto.
- Si FWL y OLS no coincidieran, habría un error de implementación. Coinciden.

Perfiles por género, especificación preferida



Source: Own calculations, GEIH 2018 (Bogotá sample).

Lectura

- Una autoridad que ignore el género va a **sobreprededir** el ingreso de las mujeres y marcarlas como subdeclarantes con más frecuencia. Eso no es neutral.
- Una autoridad que condicione en ocupación “explica” parte de la brecha con segregación. Para auditoría puede ser correcto; para equidad, no.
- Los picos distintos (50.5 vs. 45.6) implican que el ciclo de vida no es el mismo. Un perfil único por edad es una mala regla para ambos grupos.

Takeaway

La brecha incondicional es 21.2 %. Condicionar en educación la sube a 27.2 % (efecto supresor). Con horas y tipo de ocupación queda en 19.6 %. El número del informe depende de si el objeto es causalidad o predicción. Nosotros reportamos la secuencia y usamos la especificación preferida para la DIAN.