

Predicción de ingreso laboral

Problem Set 1 · Sección 3

Julián Herrera Andrés Silva Valentina Vera

Ms Economía PEG · Big Data and Machine Learning para Economía Aplicada
Universidad de los Andes

2026-20 · Grupo 3

Result overview

0.6306

RMSE de validación

S2: Preferred gender gap

Stratum

predictor más importante

$\Delta\text{RMSE} = 0.1106$ al permutar


Muestra de entrenamiento: chunks 1–7 ($N = 10,260$)

Muestra de validación: chunks 8–10 ($N = 4,501$)

LOOCV del modelo seleccionado: 0.6044

Pérdida: RMSE en log ingreso laboral mensual. LOOCV vía fórmula de leverage.

RMSE de validación



Todas las especificaciones

Model	Origin	Training RMSE	Validation RMSE	Training R^2
S2: Preferred gender gap	Section 2	0.6028	0.6306	0.539
P5: Gender-specific human capital returns	Additional	0.6396	0.6701	0.481
P4: Firm characteristics	Additional	0.6486	0.6795	0.467
P3: Labor market segmentation	Additional	0.6599	0.6861	0.448
P2: Human capital + labor supply	Additional	0.7275	0.7541	0.329
P1: Human capital	Additional	0.7812	0.7942	0.226
S1: Conditional age profile	Section 1	0.7781	0.8118	0.232
S1: Unconditional age profile	Section 1	0.8656	0.8919	0.050
S2: Unconditional gender gap	Section 2	0.8804	0.9066	0.017

El R^2 de entrenamiento no elige el modelo. El criterio de selección es RMSE de validación.

LOOCV contra validación


Model	Training RMSE	LOOCV RMSE	Validation RMSE
S2: Preferred gender gap	0.6028	0.6044	0.6306

- LOOCV calcula el error dejando una observación fuera cada vez.
- Para OLS usamos $\tilde{\epsilon}_i = \hat{\epsilon}_i / (1 - h_{ii})$, equivalente a reestimar n veces.
- LOOCV y validación son relativamente cercanos, lo que sugiere estabilidad razonable del desempeño predictivo.

Importancia: permutación en validación

Variable importance in the selected model


Increase in validation RMSE after permuting the covariate, model held fixed.



Cómo predice el modelo en función de Socioeconomic stratum

How predicted log income varies with socioeconomic stratum

Other covariates held at training-sample medians / modes.



Source: Own calculations. GEIH 2018 (Bogotá sample).

Dónde se rompe la predicción

Validation residuals against predicted log income

Selected model. A fan at high predicted values is income the model cannot see.



Lectura para la autoridad tributaria

- El mejor modelo es **S2: Preferred gender gap**. Ninguna especificación se escoge por relato: gana la que minimiza el RMSE de validación.
- Socioeconomic stratum es la variable cuya permutación deteriora más la predicción. Esto indica importancia predictiva, no causalidad.
- Los residuales muestran dónde el modelo falla. Para una autoridad tributaria, el modelo puede ayudar a priorizar casos, pero no debe automatizar auditorías.

Takeaway

S2: Preferred gender gap minimiza el RMSE de validación (0.6306). LOOCV es consistente con este resultado (0.6044). El predictor más importante es Socioeconomic stratum.