

Predicción de ingreso laboral

Problem Set 1 · Sección 3

Julián Herrera Andrés Silva Valentina Vera

MECA 4107 · Big Data and Machine Learning para Economía Aplicada
Universidad de los Andes

2026-20 · Grupo 3

Result overview

0.6160

RMSE de
validación

P6: polinomio flexible

Socioeconomic
stratum

predictor más
importante

sube el RMSE en
0.1185 al permutar

Entrenamiento: chunks 1–7 ($N = 10,260$). Validación: chunks 8–10 ($N = 4,501$).
LOOCV en entrenamiento = 0.5825, cercano al RMSE de validación: el ranking no es un artefacto del corte.

Pérdida: RMSE en log ingreso laboral mensual. LOOCV vía fórmula de leverage, no n refittings.

De interpretar a predecir

- Las Secciones 1 y 2 eligen modelos por teoría. Esta sección los juzga por **error fuera de muestra**.
- Un modelo interpretable que predice mal no sirve para detectar subdeclaración: genera demasiados falsos positivos o se pierde a los altos ingresos.
- Diseño impuesto por el enunciado: chunks 1–7 entrenan; 8–10 validan. No es un split aleatorio. Si los chunks difieren por mes o por muestreo, el RMSE de validación es una prueba más dura.


Cinco modelos adicionales, todos motivados

Un sexto modelo, más flexible (polinomio de edad, interacciones con género y educación), sirve de chequeo: si sobreajusta, el RMSE de validación debería subir.

RMSE de validación

Validation RMSE by specification

Lower is better. Selected model highlighted.



Todas las especificaciones

Model	Origin	Training RMSE	Validation RMSE	Training R^2
P6: Flexible age, education, and hours	Additional	0.5797	0.6160	0.574
P2: Add firm size and estrato	Additional	0.5886	0.6215	0.561
P4: Cubic age and quadratic hours	Additional	0.6219	0.6533	0.510
P5: Household structure	Additional	0.6503	0.6739	0.464
P3: Gender-specific returns	Additional	0.6468	0.6772	0.470
P1: Add formality	Additional	0.6531	0.6784	0.459
S2: Preferred gender gap	Section 2	0.6877	0.7140	0.400
S1: Conditional age profile	Section 1	0.7781	0.8118	0.232
S1: Unconditional age profile	Section 1	0.8656	0.8919	0.050
S2: Unconditional gender gap	Section 2	0.8804	0.9066	0.017

El R^2 de entrenamiento no elige el modelo. El RMSE de validación sí.

LOOCV contra validación


Model	Training RMSE	LOOCV RMSE	Validation RMSE
P6: Flexible age, education, and hours	0.5797	0.5825	0.6160

- LOOCV usa $\tilde{\varepsilon}_i = \hat{\varepsilon}_i / (1 - h_{ii})$. Un OLS, una corrección de leverage: el mismo estimador que un loop de n regresiones, sin el costo.
- Si LOOCV y validación discrepan mucho, el corte por chunks estaría haciendo el trabajo. Aquí se mueven juntos.
- El RMSE de entrenamiento es optimista, como debe serlo.

Importancia: permutación en validación

Variable importance in the selected model


Increase in validation RMSE after permuting the covariate, model held fixed.



Cómo predice el modelo en función de Socioeconomic stratum

How predicted log income varies with socioeconomic stratum

Other covariates held at training-sample medians / modes.



Dónde se rompe la predicción

Validation residuals against predicted log income

Selected model. A fan at high predicted values is income the model cannot see.



Lectura para la autoridad tributaria

- El mejor modelo gana por validación, no por relato. El polinomio flexible que incluimos como chequeo de sobreajuste **gana**: el LOOCV no se dispara. Aquí la flexibilidad todavía compra predicción.
- Socioeconomic stratum es el insumo que más duele perder. En Bogotá el estrato es un proxy de barrio y de red. Para fiscalización es observable; no es un salario. Usarlo como filtro mezcla ubicación con ingreso.
- Los residuales en la cola alta son el límite operativo: el modelo no distingue bien entre un alto ingreso verdadero y un alto ingreso no observado. Ahí la auditoría no puede ser automática.

Takeaway

P6: polinomio flexible minimiza el RMSE de validación (0.6160). LOOCV lo confirma (0.5825). El predictor que más importa es Socioeconomic stratum. El modelo ordena la masa de la distribución; no resuelve la cola.